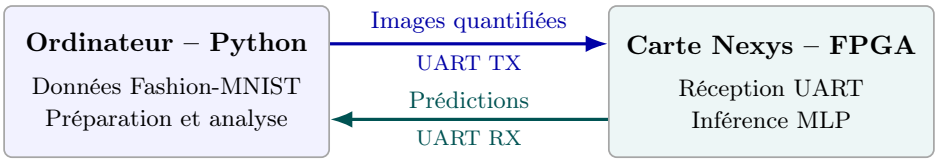
TP - Méthode d'intégration ML sur FPGA - Outils de synthèse haut niveau

1 Contexte

Vous êtes ingénieur chargé de réaliser un système de classification d'images **Fashion-MNIST** sur une carte **Nexys**. L'ordinateur gère les données et l'analyse des résultats, le FPGA effectue les inférences. Les échanges se font par **UART**.

Vous disposez d'un projet open source, initialement développé pour les cartes Lattice et Ultra96-V2 : `https://github.com/Armel-Bihan/MLP_HLS`. Votre mission est de l'adapter à la nouvelle application.



2 Travail demandé

1. **Prise en main :** cloner le dépôt GitHub et comprendre la chaîne allant du modèle PyTorch à son implémentation sur FPGA.
2. **Préparation du modèle :** récupérer Fashion-MNIST et récupérer ou entraîner un MLP de topologie $784 \to 64 \to 32 \to 10$. Vérifier ses prédictions sous Python.
3. **Adaptation de l'outil :** adapter la quantification pour le modèle choisi et la carte Nexys.
4. **Communication PC-FPGA :** définir un protocole UART pour transmettre une image et retourner sa classe prédite. Développer l'interface Python et les modules VHDL/Verilog nécessaires.
5. **Intégration et validation :** programmer la Nexys, envoyer des images depuis le PC, récupérer les prédictions et les comparer au modèle fonctionannt en float32.
6. **Analyse :** analyser les performances, identifier les principaux goulots d'étranglement.
7. **Optimisations :** proposer des améliorations et évaluer les gains des solutions mises en œuvre.
8. **Pipeline :** intégrer l'architecture pipeline de l'outil et la comparer à l'architecture séquentielle en termes de latence, débit et ressources.

3 Résultats attendus

Le système doit permettre de traiter une série d'images Fashion-MNIST depuis un script Python et d'afficher les prédictions retournées par le FPGA.

La validation principale consiste à montrer que les prédictions du FPGA correspondent à celles du modèle en float32 sur plusieurs images. Les mesures de latence, de débit et de ressources FPGA constituent une analyse complémentaire.

4 Évaluation

L'évaluation repose sur la **validation progressive en séance** et un **QCM final** à la dernière séance.